



大型语言模型

大型语言模型（英語：large language model，LLM），也称**大语言模型**，简称**大模型**，是一種基於人工神经网络的语言模型。其名稱中的「大型」指模型具有龐大的參數量（通常在數十億以上，如GPT-3含1750亿参数）以及巨大的訓練數據規模。大語言模型通常采用自监督机器学习，能夠在海量無標註的文本上训练。大语言模型专为自然语言处理任务而设计，尤其是语言生成。^{[1][2]}其中包含Gemini和GPT-4o在內的部分模型具有多模態功能，能夠同時處理文字、圖片、音頻和視頻等不同輸入形式。大多數LLM采用了生成式预训练變換器(GPT)，它们为ChatGPT、Gemini和Claude等聊天机器人提供了核心功能。这些模型能够预测人类语言语料库中固有的句法、语义和本体信息^[3]，且展示出相当多训练期间“记住”的关于世界的常识。但它们也继承了训练数据中存在的误差和偏差。^[4]

由於大語言模型的記憶和泛化能力強大，其通常能用作通用模型：即使在没有针对特定任务（例如情感分析、命名实体识别、文本翻譯、摘要生成或数学推理）进行训练的情況下，LLM往往也能夠在這些任务中表现出色。^[4]而这些功能以往通常需要定制系统才能实现。^[5]此外，基於其跨任务泛化能力，也可以针对特定任务對LLM进行微调，或通过提示工程进行引导，^[6]從而在极少量特定任务数据下实现或增强特定功能，如对话代理、代码生成、知识检索和自动推理等功能。

LLM 源于早期的统计语言模型、神经概率语言模型和循环神经网络。2017年推出的Transformer架构用自注意力机制取代了循环神经网络结构，从而实现了高效的并行化、更长的上下文处理能力以及在前所未有的数据量上进行可扩展的训练。^[7]这项创新催生了GPT、BERT等模型，这些模型展现出了大规模涌现行为，例如少样本学习和组合推理。^[8]

爲了擴充训练数据以增强模型能力，大部分LLM训练过程中存在利用網路上大量未經授權的公開藝術家作品、用戶與模型的交互以及其他公司LLM的輸出（知識蒸餾）等数据訓練AI的作法，在全球引發了廣泛的關於版權訴訟、道德爭議和私隱保護的討論。

历史

20世纪90年代，IBM对齐模型开创了统计语言建模。2001年，一个基于3亿个单词进行训练的平滑n-gram模型达到了当时最优的困惑度。^[9]在21世纪，随着互联网的普及，一些研究人员构建了互联网规模的语言数据集（“网络语料库”^[10]），并在此基础上训练统计语言模型。^{[11][12]}2009年，在大多数语言处理任务中，统计语言模型优于符号语言模型，因为它们可以有效地消化大型数据集。^[13]

在2012年左右神经网络在图像处理领域占据主导地位后^[14]，它们也被应用于语言建模。谷歌于2016年将其翻译服务转换为神经机器翻译。就像在Transformer架構出现之前的语言模型一样，它由seq2seq深度LSTM网络完成。

在2017年NeurIPS会议上，谷歌研究人员在他们的里程碑式论文《Attention Is All You Need》中介绍了Transformer架构。这篇论文的目标是改进2014年的seq2seq技术，^[7]并且主要基于Bahdanau等人在2014年开发的注意力机制。^[15]2018年，BERT被引入后迅速变得

“无处不在”。^[16]虽然原始的 Transformer 同时具有编码器和解码器块，但 BERT 是一个仅编码器的模型。随着仅解码器模型（如 GPT）通过提示解决任务的能力迅速提高，BERT 在学术和研究中的使用率在 2023 年开始下降。^[17]

仅解码器模型 GPT-1 于 2018 年推出，但 2019 年推出的 GPT-2 才引起了广泛关注，因为 OpenAI 最初认为它过于强大，无法公开发布，因为担心被恶意使用。^[18] 2020 年的 GPT-3 则更进一步，自 2024 年起仅通过 API 提供，不提供下载模型以在本地执行。2022 年面向消费者的基于浏览器的 ChatGPT 吸引了普通民众的想象力，并引起了一些媒体炒作和在线热议。^[19] 2023 年的 GPT-4 因其准确性的提高而受到称赞，并因其多模态功能而被称为“圣杯”。^[20] OpenAI 没有透露 GPT-4 的高级架构和参数数量。ChatGPT 的发布导致计算机科学的几个研究子领域的 LLM 使用率上升，包括机器人技术、软件工程和一些有社会影响的工作。^[21] 与其竞争的语言模型在很大程度上试图与 GPT 系列相提并论，至少在参数数量方面是这样。^[22]

自 2022 年以来，开源模型越来越受欢迎，尤其是最初的 BLOOM 和 LLaMA，尽管两者在使用领域都有限制。Mistral AI 的模型 Mistral 7B 和 Mixtral 8x7b 拥有更宽松的 Apache 许可证。截至 2024 年 6 月，根据 LMSYS Chatbot Arena 排行榜，Llama 3 的 700 亿参数模型的指令微调变体是最强大的开放 LLM，强于 GPT-3.5 但不如 GPT-4。^[23] 2025 年 1 月，DeepSeek 发布了 DeepSeek-R1，这是一个拥有 6710 亿个参数的开放权重模型，其性能与 OpenAI o1 相当，但成本却低得多。^[24]

自 2023 年以来，许多 LLM 已被训练为多模态，能够处理或生成其他类型的数据，例如图像或音频。这些 LLM 也称为大型多模态模型 (LMM)。^[25]

截至 2024 年，最大、功能最强大的模型均基于 Transformer 架构。最近的一些实现基于其他架构，例如循环神经网络变体和 Mamba（状态空间模型）。^{[26][27][28]}

自 2023 年以来，开放权重的大语言模型已日益成为人工智能领域的重要组成部分，有助于更广泛地参与人工智能开发，并提高模型评估的透明度。Vake 等人 (2025) 的研究表明，社区驱动的开放权重模型贡献能够显著提高其效率和性能，用户参与度在 Hugging Face 等协作平台上迅速增长。^[29] Paris 等人 (2025) 进一步指出，人工智能的开放性不应仅限于发布模型代码或权重，还应涵盖人工智能研究和部署中的包容性、问责制和伦理责任。^[30] 总而言之，这些研究强调，开放权重逻辑模型能够加速创新，增强科学可重复性，同时促进人工智能生态系统的透明化和参与性。

数据集预处理

词元化 (tokenization)

由于机器学习算法处理的是数字而不是文本，因此必须将文本转换为数字表示的词元 (token)。该过程称为词元化 (tokenization)，是数据预处理中的一个关键步骤。^[31]

词元化首先需要确定一个词汇表，然后为每个词汇表条目任意但唯一地分配整数索引，最后将嵌入与整数索引关联。确定词彙表的算法包括字节对编码 (BPE) 和 WordPiece (BERT)。不同的算法下，平均每个单词需要的词元个数也有所不同。该信息也取决于数据集的语言等因素。由于每个词元可以表示多个字符的，标记器还能够压缩数据集。^{[32][33]}

詞匯表中，通常會設計一些特殊詞元用作控制字符，例如 [MASK] 表示掩码标记（如 BERT 中使用的），[UNK]（“未知”）表示未出现在词汇表中的字符。此外，一些特殊符号用于表示特殊的文本格式。例如，“G”表示 RoBERTa 和 GPT 中的前一个空格。“##”表示 BERT 中前一个单词的延续。^[34]

例如，GPT-3（旧版）使用的 BPE 标记器会将标记器：tokenizer: texts -> series of numerical "tokens"拆分为

```
tokenizer: texts -> series of numerical "tokens"
```

由于 LLM 通常要求输入是一个整齐的高維数组，因此當並行地使用多個文本進行訓練時，必须先“填充”较短的文本（padding），直到它们与最长文本的长度匹配。

字节对编码

作为示例，考虑基于字节对编码的标记器。在第一步中，所有唯一字符（包括空格和标点符号）都被视为一组初始的 n-gram（即一组初始的 uni-gram）。随后，最常见的一对相邻字符合并为一个二元组，并用它替换该对的所有实例。然后，将最常一起出现的相邻对（先前合并的）n-gram 再次合并为更长的 n-gram，直到获得规定大小的词汇表（对于 GPT-3，大小为 50257）。^[35] 训练标记器后，任何文本都可以被它标记，只要它不包含未出现在初始 uni-gram 集中的字符。^[36]

问题

基于从主要英语语料库中提取的频率的标记词汇表对一个普通英语单词使用尽可能少的标记。然而，由这种针对英语优化的标记器编码的另一种语言的普通单词被分成次优数量的标记。对于某些语言，例如缅甸掸语，GPT-2 标记器每个单词最多可以使用 15 倍的标记。与英语相比，葡萄牙语和德语等更广泛使用的语言也“溢价 50%”。^[37]

贪心标记化还会导致文本补全出现微妙的问题。^[38]

数据清洗

在训练 LLM 的背景下，数据集通常通过删除低质量、重复或有害数据来清理。^[39] 清理后的数据集可以提高训练效率并提高下游性能。^{[40][41]} 训练过的 LLM 可用于清理数据集以训练进一步的 LLM。^[42]

随着网络上 LLM 生成内容的比例不断增加，未来的数据清理可能包括过滤掉此类内容。如果内容与人类文本相似（使过滤变得困难）但质量较低（降低在其上训练的模型的性能），则 LLM 生成的内容可能会带来问题。^[43]

合成数据

训练最大的语言模型可能需要比自然可用的更多的语言数据，或者自然发生的数据质量不够。在这些情况下，可能会使用合成数据。微软的 Phi 系列 LLM 采用另一 LLM 生成的类似教科书的数据进行训练。^[44]

注意力机制和上下文窗口

为了找出上下文窗口范围内哪些 token 彼此相关，注意力机制会使用多个注意力头为每个 token（更准确地说 是其嵌入）计算“软”权重，每个注意力头都有自己的“相关性”来计算自己的软权重。例如，小型（即 1.17 亿参数大小）GPT-2 模型有 12 个注意力头和一个只有 1000 个 token 的上下文窗口。^[46] 在其中等版本中，它有 3.45 亿个参数，包含 24 层，每层有 12 个注意力头。对于梯度下降的训练，使用的批处理大小为 512。^[47]

最大的模型，例如 2024 年 2 月推出的 Google Gemini 1.5，可以有一个大小高达 100 万的上下文窗口（1000 万的上下文窗口也“成功测试”）。^[48] 其他具有大上下文窗口的模型包括 Anthropic 的 Claude 2.1，其上下文窗口最多有 20 万个 token。^[49] 请注意，此最大值指的是输入 token 的数量，输出 token 的最大数量与输入不同，并且通常较小。例如，GPT-4 Turbo 模型的最大输出为 4096 个 token。^[50]

模型在生成下一个答案时可以考虑的对话长度也受到上下文窗口大小的限制。如果对话的长度（例如与 ChatGPT 的对话）长于其上下文窗口，则在生成下一个答案时只会考虑上下文窗口内的部分，或者模型需要应用某种算法来总结对话中太远的部分。

使上下文窗口变大的缺点包括计算成本更高，并且可能削弱对局部上下文的关注，而使上下文窗口变小可能会导致模型错过重要的长距离依赖关系。平衡它们是一个实验和特定领域的考虑问题。

模型可以预先训练，以预测片段如何继续，或者在给定训练数据集中的片段的情况下预测片段中缺少什么。^[51] 它可以是

- 自回归的（即预测片段如何继续，就像 GPT 所做的那样）：例如，给定一个片段“我喜欢吃”，模型会预测“冰淇淋”或“寿司”。
- 填空式的（即填充片段中缺失的部分，就像“BERT”^[52]所做的那样）：例如，给定一个片段“我喜欢 [] [] 淇淋”，模型会预测“吃”和“冰”作为缺失的内容。

模型可以在辅助任务上进行训练，以测试它们对数据分布的理解，例如下一句预测 (NSP)，其中呈现成对的句子，模型必须预测它们是否连续出现在训练语料库中。^[53] 在训练期间，正则化损失也用于稳定训练。然而，正则化损失通常不用于测试和评估。



当每个注意力头根据自己的标准计算其他标记与“it_”标记的相关程度时，注意到由第二列表示的第二个注意力头主要关注前两行，即标记“The”和“animal”，而第三列主要关注下面两行，即“tired”，它已被标记为两个标记。^[45]

混合专家模型

最大的 LLM 可能过于昂贵，无法直接训练和使用。对于此类模型，可以应用专家混合 (MoE)，这是谷歌研究人员自 2017 年以来一直进行的研究方向，用于训练多达 1 万亿个参数的模型。^{[54][55]}

参数数量

通常，LLM 使用单精度或半精度浮点数（float32 和 float16）进行训练。一个 float16 值有 16 位，即 2 字节，因此 10 亿个参数需要 2 GB 的空间。最大的模型通常拥有超过 1000 亿个参数，这超出了大多数消费电子产品的容量范围。^[56]

量化

训练后量化^[57]旨在通过降低已训练模型参数的精度来减少空间需求，同时尽可能保留其性能。量化可以进一步分为静态量化和动态量化。静态量化是指量化参数预先确定（通常在校准阶段），而动态量化是指在推理过程中应用量化。最简单的量化形式是将所有参数截断为给定的比特数：这适用于静态量化和动态量化，但会损失大量精度。动态量化允许每层使用不同的量化码本，可以是值查找表或线性映射（缩放因子和偏置），但代价是放弃了使用低精度运算可能带来的速度提升。

量化后的模型通常被视为已冻结，权重修改（例如微调）仅应用于原始模型。可以使用低秩自适应（low-rank adaptation, LoRA）来微调量化后的模型。^[58]

扩展性

提示工程

以前大多数只能通过（昂贵的）微调才能实现的结果，都可以通过提示工程（prompt engineering）实现，尽管仅限于单个对话的范围（更准确地说，仅限于上下文窗口的范围）。^[59]

指令调优

指令调优（Instruction Tuning）是一种微调技术，通过在包含（指令，输出）对的数据集上以监督学习方式进一步训练大型语言模型，使其更好地理解 and 执行人类指令。这种方法弥合了大型语言模型的下一个词预测目标与用户希望模型遵循人类指令之间的差距^[60]。

检索增强生成

检索增强生成（RAG）是一种通过将 LLM 与文档检索系统集成来增强其性能的方法。给定一个查询，调用文档检索器来检索最相关的文档。这通常是通过将查询和文档编码成向量来实现的，然后找到向量（通常存储在向量数据库中）与查询向量最相似的文档。之后，LLM 基于查询和从检索到的文档中包含的上下文生成输出。^{[61][62]}

基于人类反馈的强化学习

近端策略优化等基于人类反馈的强化学习算法被广泛用于进一步微调一个大语言模型^[63]，语言模型能够根据人类专家对回答做出的反馈，提供与人类价值观一致的答案，同时拒绝不适当或超出模型知识空间的问题。

推理模型


2024 年末，LLM 开发出现了一个新方向，即专门为复杂推理任务设计的模型。这些“推理模型”经过训练，在提供最终答案之前会花费更多时间生成分步解决方案，类似于人类解决问题的过程。^[64] OpenAI 于 2024 年 9 月通过其 o1 模型引入了这一趋势，随后于 2024 年 12 月推出了 o3。与传统 LLM 相比，这些模型在数学、科学和编码任务方面表现出显著的改进。例如，在国际数学奥林匹克资格考试问题上，GPT-4o 的准确率达到 13%，而 o1 的准确率达到 83%。^{[65][66]} 2025 年 1 月，中国公司深度求索（DeepSeek）发布了 DeepSeek-R1，这是一个 6710 亿参数的开放权重推理模型，其性能与 OpenAI 的 o1 相当，但运行成本明显更低。与 OpenAI 的专有模型不同，DeepSeek-R1 的开放权重特性允许研究人员研究和构建算法，但其训练数据仍保持私密。^[67] 与传统的 LLM 相比，这些推理模型通常需要每个查询更多的计算资源，因为它们执行更广泛的处理来逐步解决问题。然而，它们在需要结构化逻辑思维的领域表现出了卓越的能力，例如数学、科学研究和计算机编程。^[68]

训练成本

“大型语言模型”中的限定词“大型”本质上是模糊的，因为没有明确的阈值来定义“大型”所需的参数数量。随着时间的推移，以前被认为是“大型”的东西可能会演变。2018 年的 GPT-1 通常被认为是第一个 LLM，尽管它只有 1.17 亿个参数。在大型语言模型列表中可以看到向大型模型发展的趋势。

自 2020 年以来，软件和硬件的进步大大降低了成本，以至于在 2023 年，训练一个 120 亿参数的 LLM 的计算成本为 72,300 A100-GPU 小时，而在 2020 年，训练一个 15 亿参数的 LLM（比 2020 年最先进的 LLM 小两个数量级）的成本在 80,000 美元到 1,600,000 美元之间。^{[69][70][71]} 自 2020 年以来，大量资金投入到了越来越大的模型中。例如，2019 年训练 GPT-2（即 15 亿个参数的模型）花费了 5 万美元，而 2022 年训练 PaLM（即 5400 亿个参数的模型）花费了 800 万美元，而 Megatron-Turing NLG 530B（2021 年）花费了约 1100 万美元。^[72]

对于基于 Transformer 的 LLM，训练成本远高于推理成本。训练一个 token 需要每个参数 6 次 FLOP，而推理一个 token 需要每个参数 1 到 2 次 FLOP。^[73]



部分模型的训练成本估计

输入输出形式

多模态模型

多模态模型（英語：Large Multimodal Model, LMM），意味着“具有多种模态”，而“模态”是指一种输入或输出类型，例如视频、图像、音频、文本、本体感受等。^[74] 已经有许多专门训练过的 AI 模型来摄取一种模态并输出另一种模态，例如用于图像到标签的 AlexNet^[75]、用于图像文本到文本的视觉问答^[76]、以及用于语音到文本的语音识别。

从 LLM 创建多模态模型的常用方法是“标记”经过训练的编码器的输出。具体来说，可以构建一个可以理解图像的 LLM，如下所示：采用经过训练的 LLM，并采用经过训练的图像编码器 E 。制作一个小的多层感知器 f 这样对于任何图像 y ，后处理向量 $f(E(y))$ 具有与编码标记相同的尺寸。这是一个“图像标记”。然后，可以交错文本标记和图像标记。然后在图像文本数据集上对复合模型进行微调。可以更复杂地应用这种基本构造来改进模型。可以冻结图像编码器以提高稳定性。^[77]

Flamingo 证明了标记化方法的有效性，对一对预训练的语言模型和图像编码器进行了微调，使其在视觉问答方面的表现优于从头开始训练的模型。^[78] 使用标记化方法将 Google PaLM 模型微调为多模态模型 PaLM-E，并应用于机器人控制。^[6] LLaMA 模型也已使用标记化方法转变为多模态，以允许图像输入^[79] 和视频输入。^[80]

GPT-4 可以使用文本和图像作为输入^[81]（尽管视觉组件直到 GPT-4V^[82] 才向公众发布）；Google DeepMind 的 Gemini 也是多模态的。^[83] Mistral 于 2024 年 9 月推出了自己的多型号 Pixtral 12B。^[84]

非自然语言

LLM 处理编程语言的方式与处理自然语言的方式类似。由于代码和人类语言一样，都是以纯文本形式表示的，因此无需对词法单元的处理方式进行特殊更改。LLM 可以根据用自然语言编写的问题或指令生成代码。它们还可以用自然语言描述代码，或将其翻译成其他编程语言。LLM 最初被用作代码补全工具，但随着技术的进步，它们已发展成为自动编程工具。诸如 GitHub Copilot 之类的服务提供经过专门训练、微调或提示的 LLM，用于编程。

偏差和局限性

大语言模型偏差和局限性是自然语言处理（NLP）领域正在进行的研究。虽然 ChatGPT 等大语言模型在生成类人文本方面表现出了卓越的能力，但它们很容易受到演算法偏見影響，继承和放大训练数据中存在的偏见。这可能表现为对不同人口统计数据的歪曲表述或不公平待遇，例如基于种族^[85]、性别^[86]、语言^[87] 和文化群体^[87] 的不同观点与态度。此外，这些模型通常面临事实准确性的限制。

技术取向导致局限

机器学习和人工智能方面的专家杨立昆在GTC2025上的“炉边对话”环节提出观点，认为仅仅依靠语言和文字训练出来的AI系统，永远无法逼近人类的理解力^[88]。他也提到了世界模型（World Models）这一概念。他认为，学术界开发AI系统需要基于不同于当前token预测架构的新路径。其中一个原因是：Token具有离散的性质。“在典型的NLP任务中，token的选择范围通常在几千个左右。因此当你训练一个系统去预测下一个token，它并不能精确地预测出确切的token，而是只能基于字典中的所有可能选项生成一个概率分布。”杨利昆描述到。他又说，现实世界中人类面对的是高维、连续的数据。现在的有些AI通过像素精度的视频进行（行为或者规则）的预测，这种方法在构建认知模型方面的效果却欠佳。^[89]

幻觉

幻觉指的是大语言模型输出与客观事实不符或具有误导性的内容，其可能由模型本身或用户引导产生。^[90]

偏差

语言偏差

语言偏差是指与语言相关的一种统计抽样偏差，也就是说在信息抽样中，查询语言导致的系统偏差会使其无法准确呈现数据中的各种不同主题和观点。当前的大型语言模型主要是根据英语数据进行训练的，因此通常将英语观点视为真实可靠的观点，而系统地将非英语观点视为不相关、错误或噪音。当被问到诸如“什么是自由主义？”之类的政治意识形态的问题时，ChatGPT以英美角度为中心，而对例如说越南的“反对国家干预个人和经济生活”与中国的“限制政府权力”等视而不见。同样，回复中也没有日本、韩国、法国和德国语料库中的主流政治观点。^[87]

性别偏差

性别偏差是指这些模型产生的结果倾向于对一种性别产生不公平的偏见。这种偏差通常源于训练这些模型的数据。例如，大型语言模型通常根据传统的性别规范来分配角色和特征；它可能会将护士或秘书主要与女性联系起来，将工程师或首席执行官与男性联系起来。^{[85][91]}

政治偏差

政治偏差是指算法系统地倾向于某些政治观点、意识形态或结果，也可能表现出政治偏见。由于训练数据包含广泛的政治观点和覆盖范围，因此模型可能会生成倾向于特定政治意识形态或观点的响应，具体取决于数据中这些观点的普遍程度。^{[92][93]}

文化偏差

文化偏见是指大语言模型对特定的文化实践、信仰或传统持有偏见，由于受到训练数据中文化信息的不均衡、误导性或歧视性影响。例如，若模型的训练数据中某种文化的观点被过度代表，模型就继承这种偏差形成一定的偏见。^[94]

地域偏差

地域偏差是指大语言模型根据地理位置或国籍对人们的行为、习惯或特征做出偏见性的假设。这种偏差可能导致对特定地区的知识、成就、问题、潜力等方面的误解、低估或过度放大。^[95]

年龄偏差

年龄偏差是指大语言模型在处理或生成与年龄相关的话题时，根据年龄做出刻板印象化的假设，例如认为年长者不懂技术或年轻人缺乏责任感。^[96]

职业偏差

职业偏差是指大语言模型对特定职业持有刻板印象，将某些职业视为比其他职业更有价值或重要，或对特定职业的人群做出性格或能力上的假设。^[97]

參見

- [大型语言模型列表](#)
- [聊天機器人](#)
- [语言模型](#)
- [自然語言生成](#)
- [聊天機器人精神病](#)

参考资料

1. Bommasani, Rishi; Hudson, Drew A.; Adeli, Ehsan; Altman, Russ; Arora, Simran; von Arx, Matthew; Bernstein, Michael S.; Bohg, Jeannette; Bosselut, Antoine; Brunskill, Emma. On the Opportunities and Risks of Foundation Models. 2021. arXiv:2108.07258. 2. Brown, Tom B.; Mann, Benjamin; Ryder, Nick; Subbiah, Melanie; Kaplan, Jared; Dhariwal, Prafulla; Neelakantan, Arvind; Shyam, Pranav; Sastry, Girish; Askell, Amanda. Language Models are Few-Shot Learners. 2020. arXiv:2005.14165 [cs.CL].	3. Fathallah, Nadeen; Das, Arunav; De Giorgis, Stefano; Poltronieri, Andrea; Haase, Peter; Kovriguina, Liubov. NeOn-GPT: A Large Language Model-Powered Pipeline for Ontology Learning (PDF). Extended Semantic Web Conference 2024. Hersonissos, Greece. 2024-05-26. 4. Manning, Christopher D. Human Language Understanding & Reasoning. Daedalus. 2022, 151 (2): 127–138 [2023-06-08]. S2CID 248377870. doi:10.1162/daed_a_01905. （原始内容存档于2023-03-09） .
--	---

5. Kaplan, Jared; McCandlish, Sam; Henighan, Tom; Brown, Tom B.; Chess, Benjamin; Child, Rewon; Gray, Scott; Radford, Alec; Wu, Jeffrey; Amodei, Dario. Scaling Laws for Neural Language Models. 2020. [arXiv:2001.08361](#)  [cs.LG].
6. Brown, Tom B.; Mann, Benjamin; Ryder, Nick; Subbiah, Melanie; Kaplan, Jared; Dhariwal, Prafulla; Neelakantan, Arvind; Shyam, Pranav; Sastry, Girish; Askell, Amanda; Agarwal, Sandhini; Herbert-Voss, Ariel; Krueger, Gretchen; Henighan, Tom; Child, Rewon; Ramesh, Aditya; Ziegler, Daniel M.; Wu, Jeffrey; Winter, Clemens; Hesse, Christopher; Chen, Mark; Sigler, Eric; Litwin, Mateusz; Gray, Scott; Chess, Benjamin; Clark, Jack; Berner, Christopher; McCandlish, Sam; Radford, Alec; Sutskever, Ilya; Amodei, Dario. Larochelle, H.; Ranzato, M.; Hadsell, R.; Balcan, M.F.; Lin, H. , 编. Language Models are Few-Shot Learners (PDF). Advances in Neural Information Processing Systems (Curran Associates, Inc.). Dec 2020, **33**: 1877–1901 [2023-03-14]. [arXiv:2005.14165](#) . [doi:10.1145/3582269.3615599](#). (原始内容存档 (PDF)于 2023-11-17) .
7. Vaswani, Ashish; Shazeer, Noam; Parmar, Niki; Uszkoreit, Jakob; Jones, Llion; Gomez, Aidan N; Kaiser, Łukasz; Polosukhin, Illia. Attention is All you Need (PDF). Advances in Neural Information Processing Systems (Curran Associates, Inc.). 2017, **30** [2024-01-21]. (原始内容存档 (PDF)于 2024-02-21) .
8. Devlin, Jacob; Chang, Ming-Wei; Lee, Kenton; Toutanova, Kristina. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. 2018. [arXiv:1810.04805](#)  [cs.CL].
9. Goodman, Joshua, A Bit of Progress in Language Modeling, 2001-08-09, [Bibcode:2001cs.....8005G](#), [arXiv:cs/0108005](#) .
10. Kilgariff, Adam; Grefenstette, Gregory. Introduction to the Special Issue on the Web as Corpus. Computational Linguistics. September 2003, **29** (3): 333–347 [2025-01-20]. ISSN 0891-2017. [doi:10.1162/089120103322711569](#). (原始内容存档于 2024-06-16) .
11. Banko, Michele; Brill, Eric. Scaling to very very large corpora for natural language disambiguation. Proceedings of the 39th Annual Meeting on Association for Computational Linguistics - ACL '01 (Morristown, NJ, USA: Association for Computational Linguistics). 2001: 26–33 [2025-01-20]. [doi:10.3115/1073012.1073017](#). (原始内容存档于 2024-09-22) .
12. Resnik, Philip; Smith, Noah A. The Web as a Parallel Corpus. Computational Linguistics. September 2003, **29** (3): 349–380 [2024-06-07]. ISSN 0891-2017. [doi:10.1162/089120103322711578](#) . (原始内容存档于 2024-06-07) .
13. Halevy, Alon; Norvig, Peter; Pereira, Fernando. The Unreasonable Effectiveness of Data. IEEE Intelligent Systems. March 2009, **24** (2): 8–12 [2025-01-20]. ISSN 1541-1672. [doi:10.1109/MIS.2009.36](#). (原始内容存档于 2024-10-04) .

14. Chen, Leiyu; Li, Shaobo; Bai, Qiang; Yang, Jing; Jiang, Sanlong; Miao, Yanming. Review of Image Classification Algorithms Based on Convolutional Neural Networks. Remote Sensing. 2021, **13** (22): 4712. Bibcode:2021RemS...13.4712C. doi:10.3390/rs13224712 .
15. Bahdanau, Dzmitry; Cho, Kyunghyun; Bengio, Yoshua. Neural Machine Translation by Jointly Learning to Align and Translate. 2014. [arXiv:1409.0473](#)  [cs.CL].
16. Rogers, Anna; Kovaleva, Olga; Rumshisky, Anna. A Primer in BERTology: What We Know About How BERT Works. Transactions of the Association for Computational Linguistics. 2020, **8**: 842–866 [2024-01-21]. [S2CID 211532403](#). [arXiv:2002.12327](#) . doi:10.1162/tacl_a_00349. (原始内容存档于2022-04-03) .
17. Movva, Rajiv; Balachandar, Sidhika; Peng, Kenny; Agostini, Gabriel; Garg, Nikhil; Pierson, Emma. Topics, Authors, and Institutions in Large Language Model Research: Trends from 17K arXiv Papers. Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2024: 1223–1243 [2024-12-08]. [arXiv:2307.10700](#) . doi:10.18653/v1/2024.naacl-long.67. (原始内容存档于2025-04-12) .
18. Hern, Alex. [New AI fake text generator may be too dangerous to release, say creators](#). The Guardian. 2019-02-14 [2024-01-20]. (原始内容存档于2019-02-14) .
19. ChatGPT a year on: 3 ways the AI chatbot has completely changed the world in 12 months. Euronews. 2023-11-30 [2024-01-20]. (原始内容存档于2024-01-14) .
20. Heaven, Will. [GPT-4 is bigger and better than ChatGPT—but OpenAI won't say why](#). MIT Technology Review. 2023-03-14 [2024-01-20]. (原始内容存档于2023-03-17) .
21. Movva, Rajiv; Balachandar, Sidhika; Peng, Kenny; Agostini, Gabriel; Garg, Nikhil; Pierson, Emma. Topics, Authors, and Institutions in Large Language Model Research: Trends from 17K arXiv Papers. Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2024: 1223–1243 [2024-12-08]. [arXiv:2307.10700](#) . doi:10.18653/v1/2024.naacl-long.67. (原始内容存档于2025-04-12) .
22. Parameters in notable artificial intelligence systems. ourworldindata.org. 2023-11-30 [2024-01-20]. (原始内容存档于2024-10-06) .
23. LMSYS Chatbot Arena Leaderboard. huggingface.co. [2024-06-12]. (原始内容存档于2024-06-10) .

24. Sharma, Shubham. Open-source DeepSeek-R1 uses pure reinforcement learning to match OpenAI o1 — at 95% less cost. VentureBeat. 2025-01-20 [2025-01-26]. (原始内容存档于2025-01-25) (美国英语) .
25. Zia, Dr Tehseen. Unveiling of Large Multimodal Models: Shaping the Landscape of Language Models in 2024. Unite.AI. 2024-01-08 [2024-12-28]. (原始内容存档于2024-12-04) (美国英语) .
26. Peng, Bo; et al. RWKV: Reinventing RNNs for the Transformer Era. 2023. arXiv:2305.13048  [cs.CL].
27. Merritt, Rick. What Is a Transformer Model?. NVIDIA Blog. 2022-03-25 [2023-07-25]. (原始内容存档于2023-11-17) .
28. Gu, Albert; Dao, Tri, Mamba: Linear-Time Sequence Modeling with Selective State Spaces, 2023-12-01, arXiv:2312.00752 
29. Vake, Domen; Štílik, Bogdan; Vikić, Jernej; Tosić, Aleksandar. Is Open Source the Future of AI? A Data-Driven Approach. Applied Sciences. 2025-03-05, **15** (5): 2790. ISSN 2076-3417. doi:10.3390/app15052790  (英语) .
30. Paris, Tamara; Moon, AJung; Guo, Jin L.C. Opening the Scope of Openness in AI. Proceedings of the 2025 ACM Conference on Fairness, Accountability, and Transparency. Association for Computing Machinery: 1293–1311. 2025-06-23. doi:10.1145/3715275.3732087 .
31. 赵鑫, 李军毅, 周昆, 唐天一, 文继荣. 大语言模型. 北京: 高等教育出版社. 2024.
32. Yennie Jun. All languages are NOT created (tokenized) equal. Language models cost much more in some languages than others. 2023-05-03 [2023-08-17]. (原始内容存档于2023-08-17) . "In other words, to express the same sentiment, some languages require up to 10 times more tokens."
33. Petrov, Aleksandar; Malfa, Emanuele La; Torr, Philip; Bibi, Adel. Language Model Tokenizers Introduce Unfairness Between Languages. NeurIPS. 2023-06-23 [2023-09-16]. arXiv:2305.15425 . (原始内容存档于2023-12-15) –通过 openreview.net.
34. Kaushal, Ayush; Mahowald, Kyle, What do tokens know about their characters and how do they know it?, 2022-06-06, arXiv:2206.02608 
35. OpenAI API. platform.openai.com. [2023-04-30]. (原始内容存档于2023-04-23) .
36. Paaß, Gerhard; Giesselbach, Sven. Pre-trained Language Models. Foundation Models for Natural Language Processing. Artificial Intelligence: Foundations, Theory, and Algorithms. 2022: 19–78 [2023-08-03]. ISBN 9783031231902. doi:10.1007/978-3-031-23190-2_2. (原始内容存档于2023-08-03) .
37. Petrov, Aleksandar; Emanuele La Malfa; Torr, Philip H. S.; Bibi, Adel. Language Model Tokenizers Introduce Unfairness Between Languages. 2023. arXiv:2305.15425  [cs.CL].
38. Lundberg, Scott. The Art of Prompt Design: Prompt Boundaries and Token Healing. Medium. 2023-12-12 [2024-08-05]. (原始内容存档于2024-08-05) (英语) .

39. Dodge, Jesse; Sap, Maarten; Marasovic, Ana; Agnew, William; Ilharco, Gabriel; Groeneveld, Dirk; Mitchell, Margaret; Gardner, Matt. Documenting Large Webtext Corpora: A Case Study on the Colossal Clean Crawled Corpus. 2021. [arXiv:2104.08758](#) [cs.CL].
40. Lee, Katherine; Ippolito, Daphne; Nystrom, Andrew; Zhang, Chiyuan; Eck, Douglas; Callison-Burch, Chris; Carlini, Nicholas. [Deduplicating Training Data Makes Language Models Better](#) (PDF). Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. May 2022,. 1: Long Papers: 8424–8445 [2025-02-07]. [doi:10.18653/v1/2022.acl-long.577](#). (原始内容存档 (PDF)于 2024-09-30) .
41. Li, Yuanzhi; Bubeck, Sébastien; Eldan, Ronen; Del Giorno, Allie; Gunasekar, Suriya; Lee, Yin Tat, Textbooks Are All You Need II: phi-1.5 technical report, 2023-09-11, [arXiv:2309.05463](#)
42. Lin, Zhenghao; Gou, Zhibin; Gong, Yeyun; Liu, Xiao; Shen, Yelong; Xu, Ruochen; Lin, Chen; Yang, Yujiu; Jiao, Jian. Rho-1: Not All Tokens Are What You Need. 2024-04-11. [arXiv:2404.07965](#) [cs.CL].
43. Brown, Tom B.; et al. Language Models are Few-Shot Learners. 2020. [arXiv:2005.14165](#) [cs.CL].
44. Abdin, Marah; Jacobs, Sam Ade; Awan, Ammar Ahmad; Aneja, Jyoti; Awadallah, Ahmed; Awadalla, Hany; Bach, Nguyen; Bahree, Amit; Bakhtiari, Arash. Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone. 2024-04-23. [arXiv:2404.14219](#) [cs.CL].
45. Allamar, Jay. [Illustrated transformer](#). [2023-07-29]. (原始内容存档于 2023-07-25) .
46. Allamar, Jay. [The Illustrated GPT-2 \(Visualizing Transformer Language Models\)](#). [2023-08-01]. (原始内容存档于 2019-08-13) .
47. Paaß, Gerhard; Giesselbach, Sven. [Pre-trained Language Models](#). Foundation Models for Natural Language Processing. Artificial Intelligence: Foundations, Theory, and Algorithms. 2022: 19–78 [2023-08-03]. ISBN 9783031231902. [doi:10.1007/978-3-031-23190-2_2](#). (原始内容存档于 2023-08-03) .
48. [Our next-generation model: Gemini 1.5](#). Google. 2024-02-15 [2024-02-18]. (原始内容存档于 2024-02-18) .
49. [Long context prompting for Claude 2.1](#). 2023-12-06 [2024-01-20]. (原始内容存档于 2024-08-27) .
50. [Rate limits](#). openai.com. [2024-01-20]. (原始内容存档于 2024-02-02) .
51. Zaib, Munazza; Sheng, Quan Z.; Emma Zhang, Wei. [A Short Survey of Pre-trained Language Models for Conversational AI-A New Age in NLP](#). Proceedings of the Australasian Computer Science Week Multiconference. 2020-02-04: 1–4. ISBN 9781450376976. S2CID 211040895. [arXiv:2104.10810](#). [doi:10.1145/3373017.3373028](#).
52. Jurafsky, Dan; Martin, James H. [Speech and Language Processing](#) (PDF) 3rd edition draft. 2023-01-07 [2022-05-24]. (原始内容存档 (PDF)于 2023-03-23) .
53. Jurafsky, Dan; Martin, James H. [Speech and Language Processing](#) (PDF) 3rd edition draft. 2023-01-07 [2022-05-24]. (原始内容存档 (PDF)于 2023-03-23) .

54. Shazeer, Noam; Mirhoseini, Azalia; Maziarz, Krzysztof; Davis, Andy; Le, Quoc; Hinton, Geoffrey; Dean, Jeff. Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. 2017-01-01. [arXiv:1701.06538](#)  [cs.LG].
55. Lepikhin, Dmitry; Lee, Hyoungho; Xu, Yuanzhong; Chen, Dehao; Firat, Orhan; Huang, Yanping; Krikun, Maxim; Shazeer, Noam; Chen, Zhifeng. GShard: Scaling Giant Models with Conditional Computation and Automatic Sharding. 2021-01-12. [arXiv:2006.16668](#)  [cs.CL].
56. Mann, Tobias. How to run an LLM locally on your PC in less than 10 minutes. [www.theregister.com](#). [2024-05-17].
57. Nagel, Markus; Amjad, Rana Ali; Baalen, Mart Van; Louizos, Christos; Blankevoort, Tijmen. Up or Down? Adaptive Rounding for Post-Training Quantization. Proceedings of the 37th International Conference on Machine Learning (PMLR). 2020-11-21: 7197–7206 [2023-06-14]. (原始内容存档于 2023-06-14) .
58. Mittal, Aayush Mittal. LoRa, QLoRA and QA-LoRA: Efficient Adaptability in Large Language Models Through Low-Rank Matrix Factorization. Unite.AI. 2023-10-24 [2025-11-16] (美国英语) .
59. Wei, Jason; Tay, Yi; Bommasani, Rishi; Raffel, Colin; Zoph, Barret; Borgeaud, Sebastian; Yogatama, Dani; Bosma, Maarten; Zhou, Denny; Metzler, Donald; Chi, Ed H.; Hashimoto, Tatsunori; Vinyals, Oriol; Liang, Percy; Dean, Jeff; Fedus, William. Emergent Abilities of Large Language Models. Transactions on Machine Learning Research. 2022-08-31 [2023-03-19]. ISSN 2835-8856. (原始内容存档于 2023-03-22) .
60. What is instruction tuning?. IBM. [2024-12-09]. (原始内容存档于 2024-12-09) .
61. Lewis, Patrick; Perez, Ethan; Piktus, Aleksandra; Petroni, Fabio; Karpukhin, Vladimir; Goyal, Naman; Küttler, Heinrich; Lewis, Mike; Yih, Wen-tau; Rocktäschel, Tim; Riedel, Sebastian; Kiela, Douwe. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems (Curran Associates, Inc.). 2020, **33**: 9459–9474 [2023-06-12]. [arXiv:2005.11401](#) . (原始内容存档于 2023-06-12) .
62. Kiela, Douwe; Riedel, Sebastian; Lewis, Patrick; Piktus, Aleksandra. Retrieval Augmented Generation: Streamlining the creation of intelligent natural language processing models. Meta. 2020-09-28.
63. Ouyang, Long; Wu, Jeff; Jiang, Xu; Almeida, Diogo; Wainwright, Carroll L.; Mishkin, Pamela; Zhang, Chong; Agarwal, Sandhini; Slama, Katarina; Ray, Alex; Schulman, John; Hilton, Jacob; Kelton, Fraser; Miller, Luke; Simens, Maddie; Askell, Amanda; Welinder, Peter; Christiano, Paul; Leike, Jan; Lowe, Ryan. Training language models to follow instructions with human feedback. 2022. [arXiv:2203.02155](#)  [cs.CL].
64. Introducing OpenAI o1-preview. OpenAI. 2024-09-12 [2025-02-03]. (原始内容存档于 2024-11-26) .
65. Introducing OpenAI o1-preview. OpenAI. 2024-09-12 [2025-02-03]. (原始内容存档于 2024-11-26) .

66. Metz, Cade. OpenAI Unveils New A.I. That Can 'Reason' Through Math and Science Problems. The New York Times. 2024-12-20 [2025-02-03]. (原始内容存档于 2025-02-09) .
67. Gibney, Elizabeth. China's cheap, open AI model DeepSeek thrills scientists. Nature. 2025-01-30 [2025-02-03]. (原始内容存档于 2025-01-29) .
68. Metz, Cade. OpenAI Unveils New A.I. That Can 'Reason' Through Math and Science Problems. The New York Times. 2024-12-20 [2025-02-03]. (原始内容存档于 2025-02-09) .
69. Wiggers, Kyle. The emerging types of language models and why they matter. TechCrunch. 2022-04-28 [2023-03-09]. (原始内容存档于 2023-03-16) .
70. Sharir, Or; Peleg, Barak; Shoham, Yoav. The Cost of Training NLP Models: A Concise Overview. 2020. [arXiv:2004.08900](#)  [cs.CL].
71. Biderman, Stella; Schoelkopf, Hailey; Anthony, Quentin; Bradley, Herbie; Khan, Mohammad Aflah; Purohit, Shivanshu; Prashanth, USVSN Sai. Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. April 2023. [arXiv:2304.01373](#)  [cs.CL].
72. Maslej, Nestor; Fattorini, Loredana; Brynjolfsson, Erik; Etchemendy, John; Ligett, Katrina; Lyons, Terah; Manyika, James; Ngo, Helen; Niebles, Juan Carlos, Artificial Intelligence Index Report 2023, 2023-10-05, [arXiv:2310.03715](#) .
73. Section 2.1 and Table 1, Kaplan, Jared; McCandlish, Sam; Henighan, Tom; Brown, Tom B.; Chess, Benjamin; Child, Rewon; Gray, Scott; Radford, Alec; Wu, Jeffrey; Amodei, Dario. Scaling Laws for Neural Language Models. 2020. [arXiv:2001.08361](#)  [cs.LG].
74. Kiros, Ryan; Salakhutdinov, Ruslan; Zemel, Rich. Multimodal Neural Language Models. Proceedings of the 31st International Conference on Machine Learning (PMLR). 2014-06-18: 595–603 [2023-07-02]. (原始内容存档于 2023-07-02) .
75. Krizhevsky, Alex; Sutskever, Ilya; Hinton, Geoffrey E. ImageNet Classification with Deep Convolutional Neural Networks. Advances in Neural Information Processing Systems (Curran Associates, Inc.). 2012, **25** [2023-07-02]. (原始内容存档于 2023-07-02) .
76. Antol, Stanislaw; Agrawal, Aishwarya; Lu, Jiasen; Mitchell, Margaret; Batra, Dhruv; Zitnick, C. Lawrence; Parikh, Devi. VQA: Visual Question Answering. ICCV. 2015: 2425–2433 [2023-07-02]. (原始内容存档于 2023-07-02) .
77. Li, Junnan; Li, Dongxu; Savarese, Silvio; Hoi, Steven. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. 2023-01-01. [arXiv:2301.12597](#)  [cs.CV].

78. Alayrac, Jean-Baptiste; Donahue, Jeff; Luc, Pauline; Miech, Antoine; Barr, Iain; Hasson, Yana; Lenc, Karel; Mensch, Arthur; Millican, Katherine; Reynolds, Malcolm; Ring, Roman; Rutherford, Eliza; Cabi, Serkan; Han, Tengda; Gong, Zhitao. Flamingo: a Visual Language Model for Few-Shot Learning. Advances in Neural Information Processing Systems. 2022-12-06, **35**: 23716–23736 [2023-07-02]. [arXiv:2204.14198](#) . (原始内容存档于 2023-07-02) .
79. Liu, Haotian; Li, Chunyuan; Wu, Qingyang; Lee, Yong Jae. Visual Instruction Tuning. 2023-04-01. [arXiv:2304.08485](#)  [cs.CV].
80. Zhang, Hang; Li, Xin; Bing, Lidong. Video-LLaMA: An Instruction-tuned Audio-Visual Language Model for Video Understanding. 2023-06-01. [arXiv:2306.02858](#)  [cs.CL].
81. OpenAI. GPT-4 Technical Report. 2023-03-27. [arXiv:2303.08774](#)  [cs.CL].
82. OpenAI. GPT-4V(ision) System Card (PDF). 2023-09-25 [2025-02-11]. (原始内容存档 (PDF)于 2023-09-25) .
83. Pichai, Sundar, Google Keynote (Google I/O '23), timestamp 15:31, 2023-05-10 [2023-07-02]
84. Wiggers, Kyle. Mistral releases Pixtral 12B, its first multimodal model. TechCrunch. 2024-09-11 [2024-09-14]. (原始内容存档于 2024-09-14) .
85. Kotek, Hadas; Dockum, Rikker; Sun, David. Gender bias and stereotypes in Large Language Models. Proceedings of The ACM Collective Intelligence Conference. CI '23 (New York, NY, USA: Association for Computing Machinery). 2023-11-05. ISBN 979-8-4007-0113-9. doi:10.1145/3582269.3615599.
86. Davidson, Thomas; Bhattacharya, Debasmita; Weber, Ingmar. Roberts, Sarah T.; Tetreault, Joel; Prabhakaran, Vinodkumar; Waseem, Zeerak , 编. Racial Bias in Hate Speech and Abusive Language Detection Datasets. Proceedings of the Third Workshop on Abusive Language Online (Florence, Italy: Association for Computational Linguistics). 2019-08. doi:10.18653/v1/W19-3504.
87. Queenie Luo; Michael J. Puett; Michael D. Smith. A Perspectival Mirror of the Elephant: Investigating Language Bias on Google, ChatGPT, Wikipedia, and YouTube. arXiv. (原始内容存档于 2024-04-16) .
88. 杨立昆：“AGI 即将到来” 完全是无稽之谈，真正的智能要建立在世界模型之上. 麻省理工科技评论中文版. 2025-03-28 [2025-04-20] (中文 (中国大陆)) .
89. 苏霍伊；甲子光年. 杨立昆 GTC 对话实录：“AGI 即将到来” 完全是无稽之谈 | 甲子光年. 澎湃新闻. 2025-03-24 [2025-04-20] (中文 (中国大陆)) .
90. Lei Huang; Weijiang Yu; Weitao Ma. A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. arXiv. (原始内容存档于 2024-11-28) .

91. Yucong Duan; Fuliang Tang; Zhendong Guo; Yingtian Mei; Yuxing Wang; Kunguang Wu; Zeyu Yang; Shuaishuai Huang; Shiming Gong. Global Large Language Model EQ and IQ Bias Evaluation -Released by DIKWP -AC Research Group. ResearchGate. 2023. doi:10.13140/RG.2.2.12894.61762 –通过 ResearchGate (英语) .
92. Zhou, Karen; Tan, Chenhao. Bouamor, Houada; Pino, Juan; Bali, Kalika , 编. Entity-Based Evaluation of Political Bias in Automatic Summarization. Findings of the Association for Computational Linguistics: EMNLP 2023 (Singapore: Association for Computational Linguistics). 2023-12 [2023-12-26]. doi:10.18653/v1/2023.findings-emnlp.696. (原始内容存档于2024-04-24) .
93. Waight, Hannah; Yang, Eddie; Yuan, Yin; Messing, Solomon; Roberts, Margaret E.; Stewart, Brandon M.; Tucker, Joshua A. State media control impacts the output of U.S.-based LLMs. Good Authority. [2026-06-12] (美国英语) .
94. Yucong Duan; Fuliang Tang; Kunguang Wu; Zhendong Guo; Shuaishuai Huang; Yingtian Mei; Yuxing Wang; Zeyu Yang; Shiming Gong. "Ranking of Large Language Model (LLM) Cultural Bias" -- DIKWP Research Group International Standard Evaluation. ResearchGate. 2024. doi:10.13140/RG.2.2.26652.67200 –通过 ResearchGate.
95. Yucong Duan; Fuliang Tang; Kunguang Wu; Zhendong Guo; Shuaishuai Huang; Yingtian Mei; Yuxing Wang; Zeyu Yang; Shiming Gong. "Ranking of Large Language Model (LLM) Regional Bias" -- DIKWP Research Group International Standard Evaluation. ResearchGate. 2024. doi:10.13140/RG.2.2.10019.63529 –通过 ResearchGate.
96. Yucong Duan; Fuliang Tang; Kunguang Wu; Zhendong Guo; Shuaishuai Huang; Yingtian Mei; Yuxing Wang; Zeyu Yang; Shiming Gong. "The Large Language Model (LLM) Bias Evaluation (Age Bias)" -- DIKWP Research Group International Standard Evaluation. ResearchGate. 2024. doi:10.13140/RG.2.2.26397.12006 –通过 ResearchGate.
97. Yucong Duan; Fuliang Tang; Kunguang Wu; Zhendong Guo; Shuaishuai Huang; Yingtian Mei; Yuxing Wang; Zeyu Yang; Shiming Gong. "The Large Language Model (LLM) Bias Evaluation (Occupational Bias)" --DIKWP Research Group International Standard Evaluation. ResearchGate. 2024. doi:10.13140/RG.2.2.23041.67689 –通过 ResearchGate.

外部链接

- Open LLM Leaderboard (开放 LLM 排行榜旨在跟踪、排名和评估开放 LLM 和聊天机器人) (https://huggingface.co/spaces/HuggingFaceH4/open_llm_leaderboard) (页面存档备份)

(https://web.archive.org/web/20231222103236/https://huggingface.co/spaces/HuggingFaceH4/open_llm_leaderboard), 存于[互联网档案馆](#))

取自 “<https://zh.wikipedia.org/w/index.php?title=大型语言模型&oldid=94347548>”